Descrição

Neste projeto você deverá projetar e implementar um Multilayer Perceptron (MLP) inteiramente em Numpy (ou biblioteca análoga de computação numérica), capaz de resolver tanto problemas de classificação quanto problemas de regressão. Não é permitido utilizar *frameworks* de *deep learning* (PyTorch, TensorFlow, JAX, …) em nenhuma etapa: o *backward pass* da rede deve ser computado por um motor de diferenciação automática desenvolvido por você, também em Numpy.

A diferenciação automática é um dos recursos centrais de todos os *frameworks* modernos de redes neurais artificiais. Sua principal funcionalidade é permitir que qualquer função que possa ser computada no *framework* possa também ser derivada. O MLP deste projeto deve ser construído sobre esse recurso: o *forward pass* é expresso com as operações do motor e os gradientes usados no treinamento são obtidos exclusivamente pelo *backward pass* do motor, sem derivadas codificadas manualmente por camada.

Requisitos do motor de diferenciação automática

O motor de diferenciação automática deverá suportar operações com escalares e operações matriciais (Numpy). No mínimo, as seguintes operações devem estar disponíveis, com seus respectivos *backward passes*:

1) Soma, subtração, produto e divisão entre escalares ou entre escalar e matriz;
2) Multiplicação de matrizes;
3) Exponenciação, radiciação e logaritmos (de escalares ou com *broadcast* para matrizes);
4) Somatório.

Serão observadas a completude e a corretude do motor: para toda operação suportada, o gradiente produzido pelo *backward pass* deve estar correto. Recomenda-se verificar a corretude comparando os gradientes com aproximações por diferenças finitas.

Requisitos do MLP

O MLP desenvolvido deverá possibilitar, no mínimo, as seguintes hiperparametrizações:

1) Número de camadas ocultas;
2) Número de unidades em cada camada oculta;
3) Funções de ativação: *Sigmoid*, *Tanh*, *ReLU*, *Leaky ReLU* e Linear;
4) Função de custo: BCE e *Mean Squared Error*;
5) Otimizador: SGD e Adam;
6) Método de inicialização dos pesos: He, Xavier, Normal ou Uniforme.

Além disso, deve ser possível exportar um arquivo (em formato definido por você) que contenha tanto a topologia da rede (camadas, funções de ativação, …) quanto os pesos do modelo treinado. Também deve ser possível importar um desses arquivos e fazer inferência com a rede pré-treinada, sem novo treinamento.

Conjuntos de dados

O MLP deverá ser testado em pelo menos 2 conjuntos de dados. Obrigatoriamente devem ser explorados um problema de classificação e um problema de regressão. Abaixo constam algumas sugestões, mas outros conjuntos podem ser utilizados:

1) Boston Housing;
2) IRIS;
3) MNIST 1D;
4) MNIST;
5) Fashion MNIST.

Experimentos

Além de buscar bons resultados nos conjuntos de dados escolhidos, você deverá mostrar na prática o problema do gradiente que se dissipa ou do gradiente explosivo, provocando o fenômeno em uma configuração adequada da rede e evidenciando o comportamento nos gráficos de monitoramento.

Monitoramento

Durante o treinamento das redes, os seguintes gráficos deverão ser produzidos:

1) Histograma das ativações e dos gradientes ao longo do treinamento (auxilia na identificação do problema do gradiente que se dissipa);
2) Função de custo vs. iteração (ou época), tanto em treino quanto em validação;
3) Métrica de avaliação (acurácia, R^2, …) vs. iteração (ou época), tanto em treino quanto em validação.